Рубежный контроль №2

Румянцев Олег

Группа ИУ5-22М

Тема: Методы обработки текстов.

Решение задачи классификации текстов.

Необходимо решить задачу классификации текстов на основе любого выбранного Вами датасета. Классификация может быть бинарной или многоклассовой. Целевой признак из выбранного Вами датасета может иметь любой физический смысл, примером является задача анализа тональности текста.

Необходимо сформировать два варианта векторизации признаков - на основе CountVectorizer и на основе TfidfVectorizer.

В качестве классификаторов необходимо использовать два классификатора по варианту для Вашей группы: RandomForestClassifier, Complement Naive Bayes (CNB)

Для каждого метода необходимо оценить качество классификации. Сделайте вывод о том, какой вариант векторизации признаков в паре с каким классификатором показал лучшее качество.

Стр. 1 из 7 25.05.2021, 21:38

```
In [1]:
         # This Python 3 environment comes with many helpful analytics libraries insta
         # It is defined by the kaggle/python Docker image: https://github.com/kaggle/
         # For example, here's several helpful packages to load
         import numpy as np # linear algebra
         import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)
         from typing import Dict, Tuple
         from scipy import stats
         from sklearn.preprocessing import LabelEncoder
         from sklearn.feature extraction.text import CountVectorizer, TfidfVectorizer
         from sklearn.model_selection import train_test_split
         from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
         from sklearn.linear_model import LogisticRegression
         from sklearn.model selection import GridSearchCV, RandomizedSearchCV
         from sklearn.metrics import accuracy_score, balanced_accuracy_score
         from sklearn.metrics import precision_score, recall_score, f1_score, classifi
         from sklearn.metrics import confusion_matrix
         from sklearn.model_selection import cross_val_score
         from sklearn.pipeline import Pipeline
         from sklearn.ensemble import RandomForestClassifier
         from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squ
         from sklearn.metrics import roc_curve, roc_auc_score
         from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, Linea
         from sklearn.naive_bayes import ComplementNB
         import seaborn as sns
         import matplotlib.pyplot as plt
         %matplotlib inline
         sns.set(style="ticks")
         # Input data files are available in the read-only "../input/" directory
         # For example, running this (by clicking run or pressing Shift+Enter) will li
         import os
         for dirname, _, filenames in os.walk('/kaggle/input'):
             for filename in filenames:
                 print(os.path.join(dirname, filename))
         # You can write up to 20GB to the current directory (/kaggle/working/) that g
         # You can also write temporary files to /kaggle/temp/, but they won't be save
         pd.set_option("display.max_columns", None)
        /kaggle/input/amazon-fine-food-reviews/hashes.txt
```

/kaggle/input/amazon-fine-food-reviews/hashes.txt /kaggle/input/amazon-fine-food-reviews/Reviews.csv /kaggle/input/amazon-fine-food-reviews/database.sqlite

Стр. 2 из 7 25.05.2021, 21:38

```
In [2]:
         def accuracy_score_for_classes(
             y_true: np.ndarray,
             y_pred: np.ndarray) -> Dict[int, float]:
             Вычисление метрики accuracy для каждого класса
             y_true - истинные значения классов
             y_pred - предсказанные значения классов
             Возвращает словарь: ключ - метка класса,
             значение - Accuracy для данного класса
             # Для удобства фильтрации сформируем Pandas DataFrame
             d = {'t': y_true, 'p': y_pred}
             df = pd.DataFrame(data=d)
             # Метки классов
             classes = np.unique(y_true)
             # Результирующий словарь
             res = dict()
             # Перебор меток классов
             for c in classes:
                 # отфильтруем данные, которые соответствуют
                 # текущей метке класса в истинных значениях
                 temp_data_flt = df[df['t']==c]
                 # расчет ассиracy для заданной метки класса
                 temp_acc = accuracy_score(
                     temp_data_flt['t'].values,
                     temp_data_flt['p'].values)
                 # сохранение результата в словарь
                 res[c] = temp_acc
             return res
         def print_accuracy_score_for_classes(
             y_true: np.ndarray,
             y_pred: np.ndarray):
             Вывод метрики accuracy для каждого класса
             accs = accuracy_score_for_classes(y_true, y_pred)
             if len(accs)>0:
                 print('Μετκα \t Accuracy')
             for i in accs:
                 print('{} \t {}'.format(i, accs[i]))
In [5]:
         train = pd.read csv('/kaggle/input/amazon-fine-food-reviews/Reviews.csv')
In [6]:
         print(train.shape)
        (568454, 10)
In [7]:
         train.head()
Out [7]:
           Id
                 ProductId
                                     UserId ProfileName HelpfulnessNumerator HelpfulnessDenor
               B001E4KFG0 A3SGXH7AUHU8GW
                                                                        1
                                             delmartian
```

Cтр. 3 из 7 25.05.2021, 21:38

		Id	ProductId	UserId	ProfileName	HelpfulnessNumerator	HelpfulnessDenor
	1	2	B00813GRG4	A1D87F6ZCVE5NK	dll pa	0	
	2	3	B000LQOCH0	ABXLMWJIXXAIN	Natalia Corres "Natalia Corres"	1	
	3	4	B000UA0QIQ	A395BORC6FGVXV	Karl	3	
	4	5	B006K2ZZ7K	A1UQRSCLF8GW1T	Michael D. Bigham "M. Wassir"	0	
In [8]:	train.Score.value_counts()						
Out[8]:	5 4 1 3 2 Na		363122 80655 52268 42640 29769 Score, dtyp	e: int64			

Очистка данных

Стр. 4 из 7

```
In [23]:
          import re
          import nltk
          from nltk.corpus import stopwords
          stop = set(stopwords.words('english'))
          def test(word):
              if word.isalpha() and len(word) > 2 and word.lower() not in stop:
                   s=(sno.stem(word.lower()))
                   return s
              else:
                   pass
          #initialising the snowball stemmer
          sno = nltk.stem.SnowballStemmer('english')
          def preprocess_sentence(w):
              w = re.sub('\t\n', '', w)
              w = re.sub(r'http\S+', '', w)
              w = re.sub(r"([?.!,])", r" \1 ", w)
w = re.sub(r'[" "]+', " ", w)
              w = re.sub(r''[^a-zA-Za-sA-S?.!, ']+'', ''', w)
              w = w.strip().split()
              text = [test(x) for x in w if test(x)]
              return ' '.join(text)
In [24]:
          train.Text = train.Text.apply(preprocess_sentence)
In [25]:
          vocabVect = CountVectorizer()
          vocabVect.fit(train.Text)
          corpusVocab = vocabVect.vocabulary_
          print('Количество сформированных признаков - {}'.format(len(corpusVocab)))
         Количество сформированных признаков - 73376
In [13]:
          for i in list(corpusVocab)[1:10]:
              print('{}={}'.format(i, corpusVocab[i]))
         bought=10722
         several=83580
         of=64753
         the=94178
         vitality=101486
         canned=13501
         dog=27448
         food=35881
         products=73379
In [14]:
          tfidfv = TfidfVectorizer(ngram range=(1,3))
          tfidf_ngram_features = tfidfv.fit_transform(train.Text)
          tfidf_ngram_features
out[14]: <568454x14619665 sparse matrix of type '<class 'numpy.float64'>'
```

Cтр. 5 из 7 25.05.2021, 21:38

```
In [19]:
          def VectorizeAndClassify(vectorizers_list, classifiers_list):
              for v in vectorizers_list:
                  for c in classifiers_list:
                      pipeline1 = Pipeline([("vectorizer", v), ("classifier", c)])
                      score = cross_val_score(pipeline1, train.Text[:10000], train.Scor
                      print('Векторизация - {}'.format(v))
                      print('Модель для классификации — {}'.format(c))
                      print('Accuracy = {}'.format(score))
                      print('=======')
In [26]:
          vectorizers_list = [CountVectorizer(vocabulary = corpusVocab), TfidfVectorize
          classifiers_list = [RandomForestClassifier(), ComplementNB()]
          VectorizeAndClassify(vectorizers_list, classifiers_list)
         Векторизация — CountVectorizer(vocabulary={'aa': 0, 'aaa': 1, 'aaaa': 2, 'aaa
         aa': 3,
                                      'aaaaaaa': 4, 'aaaaaaaaaa': 5, 'aaaaaaaaaaa': 6,
                                      'aaaaaaaaaaaa': 7, 'aaaaaaaaaaaaa': 8,
                                      'aaaaaaaaaaaaaa': 9, 'aaaaaaaaaaaaaaa': 10.
                                      1,
                                      'aaaaaaaaaaaaaaaaaargh': 12,
                                      'aaaaaaaaaaaaaaaccccccckkkkkk': 13,
                                      'aaaaaaaahhhhhh': 14, 'aaaaaaah': 15, 'aaaaaaaahhhhhh': 16, 'aaaaaaarrrrrggghhh': 17,
                                      'aaaaaaah': 18, 'aaaaaahhh': 19, 'aaaaaahhhh': 20,
                                      'aaaaaahhhhhh': 21, 'aaaaaahhhhhyaaaaaa': 22,
                                      'aaaaaand': 23, 'aaaaaawwwwwwwwww': 24,
                                      'aaaaah': 25, 'aaaaahhhhhhhhhhhhhhhhh': 26,
                                      'aaaaallll': 27, 'aaaaawsom': 28, 'aaaah': 29,
         ...})
         Модель для классификации — RandomForestClassifier()
         Accuracy = 0.6243000724787536
         Векторизация - CountVectorizer(vocabulary={'aa': 0, 'aaa': 1, 'aaaa': 2, 'aaa
         aa': 3,
                                      'aaaaaaa': 4, 'aaaaaaaaaaa': 5, 'aaaaaaaaaaa': 6,
                                      'aaaaaaaaaaaaa': 7, 'aaaaaaaaaaaaa': 8, 'aaaaaaaaaaaaaa': 9, 'aaaaaaaaaaaaaa: 10,
                                      1,
                                      'aaaaaaaaaaaaaaaaaargh': 12,
                                      'aaaaaaaaaaaaaaacccccckkkkkk': 13,
                                      'aaaaaaaaagghh': 14, 'aaaaaaah': 15,
                                      'aaaaaaahhhhhh': 16, 'aaaaaaarrrrrggghhh': 17,
                                      'aaaaaahhhhh': 19, 'aaaaaahhhh': 20, 'aaaaaahhhhh': 21, 'aaaaaahhhhhyaaaaaa': 22,
                                      'aaaaaaand': 23, 'aaaaaaawwwwwwwwwww': 24,
                                      'aaaaah': 25, 'aaaaahhhhhhhhhhhhhhhhh': 26,
                                      'aaaaallll': 27, 'aaaaawsom': 28, 'aaaah': 29,
         ...})
         Модель для классификации — ComplementNB()
         Accuracy = 0.6250998525167454
         Векторизация - TfidfVectorizer(vocabulary={'aa': 0, 'aaa': 1, 'aaaa': 2, 'aaa
         aa': 3,
```

Стр. 6 из 7 25.05.2021, 21:38

```
'aaaaaaa': 4, 'aaaaaaaaaa': 5, 'aaaaaaaaaaa': 6,
                            'aaaaaaaaaaaa': 7, 'aaaaaaaaaaaaa': 8,
                            'aaaaaaaaaaaaaa:: 9, 'aaaaaaaaaaaaaa:: 10,
                            1,
                            'aaaaaaaaaaaaaaaaaargh': 12,
                            'aaaaaaaaaaaaaaccccccckkkkkk': 13,
                            'aaaaaaaagghh': 14, 'aaaaaaah': 15,
                            'aaaaaaahhhhhhh': 16, 'aaaaaaarrrrrggghhh': 17,
                            'aaaaaaah': 18, 'aaaaaahhh': 19, 'aaaaaahhhh': 20,
                            'aaaaaahhhhhh': 21, 'aaaaaahhhhhyaaaaaa': 22,
                            'aaaaaand': 23, 'aaaaaawwwwwwwwww': 24,
                            'aaaaah': 25, 'aaaaahhhhhhhhhhhhhhhhhh': 26,
                            'aaaaallll': 27, 'aaaaawsom': 28, 'aaaah': 29,
...})
Модель для классификации — RandomForestClassifier()
Accuracy = 0.6224999224577527
_____
Векторизация - TfidfVectorizer(vocabulary={'aa': 0, 'aaa': 1, 'aaaa': 2, 'aaa
aa': 3,
                            'aaaaaaa': 4, 'aaaaaaaaaaa': 5, 'aaaaaaaaaaa': 6,
                            'aaaaaaaaaaaaa': 7, 'aaaaaaaaaaaaa': 8, 'aaaaaaaaaaaaaaa': 9, 'aaaaaaaaaaaaaa: 10,
                            1,
                            'aaaaaaaaaaaaaaaaaargh': 12,
                            'aaaaaaaaaaaaaaacccccckkkkkk': 13,
                            'aaaaaaaahhhhhh': 14, 'aaaaaaah': 15, 'aaaaaaaarrrrrggghhh': 17,
                            'aaaaaahhhhh': 19, 'aaaaaahhhhh': 20, 'aaaaaahhhhh': 21, 'aaaaaahhhhhyaaaaaa': 22,
                            'aaaaaand': 23, 'aaaaaawwwwwwwwwww': 24,
                            'aaaaah': 25, 'aaaaahhhhhhhhhhhhhhhhhh': 26,
                            'aaaaallll': 27, 'aaaaawsom': 28, 'aaaah': 29,
...})
Модель для классификации — ComplementNB()
Accuracy = 0.6182000023637636
```

Лучший результат показала модель ComplementNB c CountVectorizer

```
In []:
```

Стр. 7 из 7